

Classificação Estilométrica com Teoria de Conjuntos Fuzzy e Raciocínio Aproximado

Victor Löfgren Sattamini

Programa de Pós-Graduação em Ciências Computacionais e Modelagem Matemática
(PPG-CompMat)
IME UERJ

11 de Dezembro de 2025

Resumo

Este trabalho apresenta um classificador baseado em lógica fuzzy para detecção de textos gerados por LLM - Large Language Models em português do Brasil. A abordagem utiliza propriedades quantitativas da escrita associadas a funções de pertinência triangulares que expressam o grau de pertencimento de um texto a categorias linguísticas interpretáveis. Os parâmetros das funções são determinados de forma orientada a dados, usando quantis (33%, 50%, 66%) das distribuições observadas no conjunto de treino, eliminando a necessidade de conhecimento especialista. O sistema de inferência fuzzy estima os graus de pertinência através de média aritmética para estimar a probabilidade de um texto ser autoral ou gerado por LLM. Avaliamos o classificador em um corpus balanceado de 100.000 amostras usando validação cruzada estratificada de 5 folds. O classificador fuzzy alcançou ROC AUC de 89,34% ($\pm 0,04\%$), demonstrando desempenho competitivo comparado a métodos estatísticos (regressão logística: 97,03%, LDA: 94,12%) e neurais mais complexos. Além disso, o classificador apresentou variância 3–4 \times menor que métodos comparativos, indicando maior robustez. O custo de oportunidade entre interpretabilidade e desempenho é modesto (cerca de 8% de perda em AUC), tornando o modelo adequado para cenários onde transparência e auditabilidade são prioritárias, como educação, moderação de conteúdo e integridade científica. Este trabalho mostra que sistemas fuzzy podem competir com abordagens mais complexas, preservando vantagens cruciais de explicabilidade.

1 Introdução

Neste trabalho, exploramos o uso de lógica fuzzy como método de detecção de textos gerados por modelos de linguagem de grande porte (LLMs). Para isso, construímos um classificador fuzzy baseado em métricas estilométricas - propriedades da escrita que capturam padrões linguísticos, sintáticos e semânticos. Cada métrica é associada a uma função de pertinência que expressa o grau de pertencimento de um texto a variáveis linguísticas interpretáveis, como "alta fluência" ou "baixa variação lexical".

As funções de pertinência adotadas são triangulares, determinadas por três parâmetros (a, b, c), amplamente utilizadas em sistemas fuzzy por sua simplicidade algorítmica e eficiência computacional (pedrycz1994).

O interesse em utilizar lógica fuzzy na estilometria decorre da natureza intrinsecamente gradual da linguagem. Categorias como "texto bem estruturado" ou "escrita natural" dependem de critérios de pertinência. A lógica fuzzy ocupa um espaço entre empirismo e formalidade, aproximando-se

da forma como utilizamos a linguagem natural para expressar incerteza e imprecisão (klir1995). Essa característica a torna adequada para modelar a "gradualidade" no pertencimento de um texto a uma classe (autoral ou LLM).

Ao fuzzificar métricas estilométricas e combiná-las no sistema de inferência fuzzy de regras "Se ... então", é possível estimar o grau de pertencimento de um texto a cada classe.

A principal vantagem da abordagem fuzzy é a **interpretabilidade**: ao contrário de modelos de caixa-preta, os graus de pertinência podem ser inspecionados e compreendidos por humanos, revelando em que medida cada dimensão estilométrica contribui para a decisão. Além disso, o sistema fuzzy permite incorporar conhecimento linguístico especializado na definição das funções de pertinência, embora aqui seja adotada uma abordagem orientada a dados (*data-driven*), determinando os parâmetros a partir de quantis das distribuições observadas.

A lógica fuzzy tem sido amplamente aplicada em processamento de linguagem natural, especialmente em análise de sentimentos (vashishtha2023) e classificação de texto (liu2024). Trabalhos recentes também exploram sistemas fuzzy interpretativos baseados em fundamentos axiomáticos (wang2024fuzzy) demonstrando a viabilidade de sistemas transparentes e auditáveis. Contudo, até onde sabemos, nenhum estudo anterior aplicou lógica fuzzy especificamente à detecção de textos gerados por inteligência artificial. Enquanto LLMs têm sido analisados predominantemente por métodos estatísticos ou de aprendizado profundo, este trabalho propõe a utilização de sistemas de inferência fuzzy como alternativa explicável, eficiente e de fácil interpretação.

Os resultados apresentados demonstram que classificadores fuzzy simples podem alcançar desempenho competitivo (AUC de 89%) em comparação com abordagens estatísticas mais complexas, preservando ao mesmo tempo transparência e interpretabilidade.

1.1 Fundamentos de Conjuntos Fuzzy

A teoria de conjuntos fuzzy, introduzida por Zadeh (zadeh1965), estende a teoria clássica de conjuntos ao permitir que elementos apresentem **graus de pertinência** a um conjunto, em vez de pertencimento binário (0 ou 1). Essa generalização é essencial para modelar conceitos linguísticos vagos, como "alta diversidade lexical" ou "estrutura sintática complexa", que não admitem fronteiras rígidas.

1.1.1 Definição Formal de Conjunto Fuzzy

Seja X um conjunto universo. Um conjunto fuzzy A em X é caracterizado por uma **função de pertinência** $\mu_A : X \rightarrow [0, 1]$, que atribui a cada elemento $x \in X$ um grau de pertinência $\mu_A(x)$:

$$A = \{(x, \mu_A(x)) \mid x \in X, \mu_A(x) \in [0, 1]\} \quad (1)$$

Quando $\mu_A(x) = 1$, o elemento x pertence completamente ao conjunto A . Quando $\mu_A(x) = 0$, x não pertence a A . Valores intermediários ($0 < \mu_A(x) < 1$) indicam pertencimento parcial. Essa gradualidade é a característica distintiva da lógica fuzzy em relação à lógica booleana clássica.

1.1.2 Operações sobre Conjuntos Fuzzy

As operações fundamentais sobre conjuntos fuzzy são definidas como extensões das operações clássicas (klir1995):

- **União** (operador OR): $\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$
- **Interseção** (operador AND): $\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$

- **Complemento** (operador NOT): $\mu_{\bar{A}}(x) = 1 - \mu_A(x)$

Essas operações, conhecidas como *operadores de Zadeh*, satisfazem as propriedades de comutatividade, associatividade e distributividade, e generalizam a álgebra booleana ao caso contínuo.

1.1.3 Variáveis Linguísticas e Funções de Pertinência

Uma **variável linguística** (zadeh1975linguistic) é uma variável cujos valores são palavras ou frases da linguagem natural, em vez de números. Por exemplo, a variável linguística “Diversidade Lexical” pode assumir os valores $\{baixa, média, alta\}$, cada um representado por um conjunto fuzzy.

As **funções de pertinência** modelam a semântica desses termos linguísticos. Funções triangulares, adotadas neste trabalho, são definidas por três parâmetros (a, b, c) , onde a e c delimitam a base do triângulo e b representa o ponto de pertinência máxima ($\mu(b) = 1$):

$$\mu_{\text{triangular}}(x; a, b, c) = \begin{cases} 0 & \text{se } x \leq a \\ \frac{x-a}{b-a} & \text{se } a < x \leq b \\ \frac{c-x}{c-b} & \text{se } b < x < c \\ 0 & \text{se } x \geq c \end{cases} \quad (2)$$

Funções triangulares são amplamente utilizadas pela simplicidade de implementação e baixo custo computacional, sem perda significativa de expressividade (pedrycz1994).

1.1.4 Sistemas de Inferência Fuzzy

Um **sistema de inferência fuzzy** (SIF) é composto por quatro componentes principais (wang1997):

1. **Fuzzificação**: converte valores de entrada numéricos em graus de pertinência aos conjuntos fuzzy de entrada.
2. **Base de Regras**: conjunto de regras fuzzy do tipo “Se-Então” (IF-THEN), expressando conhecimento especializado ou relações aprendidas dos dados.
3. **Motor de Inferência**: aplica operações fuzzy (min, max, produto) para agregar as regras ativadas.
4. **Defuzzificação**: converte os graus de pertinência de saída em um valor numérico (por exemplo, usando o método do centroide).

Os dois tipos mais comuns de SIF são:

- **Mamdani**: utiliza conjuntos fuzzy tanto na entrada quanto na saída, gerando saídas linguísticas. É altamente interpretável, mas computacionalmente mais custoso.
- **Takagi-Sugeno (TS)**: utiliza funções matemáticas (tipicamente lineares ou constantes) como consequentes das regras. O modelo TS de ordem zero (consequentes constantes) é computacionalmente eficiente e adequado para problemas de classificação.

Neste trabalho, adotou-se o modelo **Takagi-Sugeno de ordem zero**, no qual cada regra atribui uma classe constante (0 para autoral, 1 para LLM) com base na ativação das condições fuzzy. A decisão final é obtida pela média ponderada das saídas, ponderadas pelos graus de ativação das regras.

1.1.5 Justificativa para o Uso de Lógica Fuzzy

A escolha da lógica fuzzy para a detecção de textos gerados por LLMs fundamenta-se em três pilares:

1. **Interpretabilidade:** ao contrário de modelos de caixa-preta (redes neurais, *boosting* de gradiente), os graus de pertinência e as regras fuzzy são inspecionáveis, permitindo auditoria e compreensão do processo decisório.
2. **Robustez:** o uso de quantis para determinar os parâmetros das funções de pertinência torna o modelo resistente a valores extremos (*outliers*), resultando em variância excepcionalmente baixa ($\pm 0.04\%$).
3. **Modelagem de Incerteza:** características estilométricas apresentam gradualidade natural (um texto pode ser “moderadamente variável lexicalmente”), que a lógica fuzzy captura de forma direta, sem necessidade de discretização arbitrária.

Embora o desempenho preditivo (AUC de 89%) seja ligeiramente inferior ao de métodos estatísticos complexos (97%), essa diferença de 8 pontos percentuais representa o **custo de oportunidade** para obtenção de transparência total e estabilidade superior. Essa escolha é particularmente relevante em contextos de integridade acadêmica e auditoria, onde a explicabilidade é tão importante quanto a acurácia.

2 Fundamentos de Teoria de Conjuntos Fuzzy

2.1 Mineração de Texto

A mineração de texto consiste em extrair informações úteis de dados textuais não estruturados através de técnicas estatísticas e computacionais (**feldman2007**). Neste trabalho, transformamos documentos em vetores de variáveis quantitativas que capturam propriedades estatísticas do estilo de escrita, permitindo a aplicação de sistemas de inferência fuzzy para classificação.

2.2 Conjunto de Dados e Amostragem Estratificada

Utilizou-se um conjunto de dados textuais balanceado em português do Brasil contendo 100.000 amostras (50.000 autorais, 50.000 de LLMs), extraídas por **amostragem estratificada proporcional** de um conjunto maior com 2.331.317 documentos originais provenientes de 5 fontes distintas.

2.2.1 Fontes de Dados e População

As fontes de texto autoral incluem: (i) **BrWaC** (Brazilian Web as Corpus), um grande conjunto web de textos brasileiros coletados da internet; e (ii) **BoolQ**, contendo passagens de contexto para perguntas booleanas.

As fontes de texto gerado por LLM incluem: (i) **ShareGPT-Portuguese**, conversas em português geradas por modelos GPT; (ii) **IMDB Reviews**, resenhas traduzidas para português por modelos de tradução automática neural; e (iii) **Canarim**, conjunto de dados contendo saídas geradas por diversos LLMs em português.

2.2.2 Critérios de Inclusão e Pré-Processamento

Os textos foram submetidos aos seguintes critérios de filtragem:

1. **Comprimento mínimo:** 100 caracteres (para garantir amostra estilométrica suficiente)
2. **Comprimento máximo:** 10.000 caracteres (para evitar textos excessivamente longos)
3. **Segmentação:** textos excedendo 10.000 caracteres foram segmentados em fragmentos de até 10.000 caracteres sem sobreposição
4. **Codificação:** UTF-8, com remoção de caracteres de controle não-imprimíveis

2.2.3 Estratégia de Balanceamento

O balanceamento de classes foi obtido por **subamostragem da classe majoritária e sobreamostragem da classe minoritária** em cada estrato (fonte de dados), resultando em proporções exatamente iguais (50%/50%). A amostragem estratificada garante que cada fonte contribua proporcionalmente ao tamanho original, preservando a diversidade estilística e reduzindo viés de seleção (cochran1977).

A estratificação por fonte é essencial porque diferentes origens apresentam variações estilísticas intrínsecas (por exemplo, conversas vs. artigos formais). Ao manter a proporção de cada fonte, garante-se que o classificador seja avaliado em um conjunto representativo da população original, aumentando a validade externa dos resultados.

2.3 Características Estilométricas

Utilizamos 10 características estilométricas extraídas pelo módulo `src/features.py`, selecionadas por capturarem aspectos complementares da estrutura estatística e lexical dos textos: (1) `sent_mean` – comprimento médio de frase (tendência central); (2) `sent_std` – desvio padrão do comprimento de frase (dispersão sintática); (3) `sent_burst` – coeficiente de variação (σ/μ , dispersão relativa, também denominado *burstiness* normalizado (gptzero2023; siddharth2024burstiness)); (4) `ttr` – relação tipo-token (V/N , diversidade lexical); (5) `herdan_c` – C de Herdan ($\log V/\log N$, diversidade normalizada); (6) `hapax_prop` – proporção de hapax legomena (raridade lexical); (7) `char_entropy` – variabilidade da distribuição de caracteres (dispersão medida pela fórmula de Shannon); (8) `func_word_ratio` – proporção de palavras funcionais (estabilidade lexical, menor variância entre textos); (9) `first_person_ratio` – proporção de pronomes de primeira pessoa (subjetividade); e (10) `bigram_repeat_ratio` – proporção de tipos de bigramas que ocorrem mais de uma vez, capturando redundância local e padrões repetitivos (solaiman2019release; li2016diversity).

Do ponto de vista estatístico, todas as características são **variáveis contínuas em escala de razão**, possuindo zero absoluto e razões interpretáveis entre valores.

2.4 Funções de Pertinência Triangulares

Para cada característica, definimos três conjuntos fuzzy – “baixo”, “médio” e “alto” – representados por funções de pertinência triangulares. Uma função triangular é determinada por três parâmetros (a, b, c) e definida como:

$$\mu_{tri}(x; a, b, c) = \begin{cases} 0 & \text{se } x \leq a \text{ ou } x \geq c \\ \frac{x-a}{b-a} & \text{se } a < x < b \\ \frac{c-x}{c-b} & \text{se } b < x < c \\ 1 & \text{se } x = b \end{cases} \quad (3)$$

As funções triangulares são amplamente utilizadas em sistemas fuzzy pela simplicidade computacional e pela facilidade de interpretação (**wang1997**). Embora não sejam suaves nos vértices, fornecem aproximações satisfatórias para muitos problemas práticos.

2.5 Determinação Orientada a Dados dos Parâmetros

Ao invés de definir parâmetros manualmente, utilizamos uma abordagem **orientada por dados** baseada em quantis da distribuição observada dos dados de treinamento. Para cada característica f_i , calculamos:

- Percentil 0%: $q_0 = \min(f_i)$
- Percentil 33%: q_{33}
- Percentil 50%: q_{50} (mediana)
- Percentil 66%: q_{66}
- Percentil 100%: $q_{100} = \max(f_i)$

As funções de pertinência são então definidas como:

$$\mu_{low}(x) = \mu_{tri}(x; q_0, q_{33}, q_{50}) \quad (4)$$

$$\mu_{medium}(x) = \mu_{tri}(x; q_{33}, q_{50}, q_{66}) \quad (5)$$

$$\mu_{high}(x) = \mu_{tri}(x; q_{50}, q_{66}, q_{100}) \quad (6)$$

Esta abordagem garante que as funções de pertinência reflitam a distribuição empírica dos dados, adaptando-se automaticamente às características de cada métrica.

2.6 Orientação e Regras Fuzzy

Para determinar se valores altos ou baixos de uma característica indicam texto autoral, comparamos as medianas dos dois grupos (autoral e LLM):

- Se $\text{mediana}_{\text{autoral}}(f_i) > \text{mediana}_{\text{LLM}}(f_i)$, a orientação é **direta**: valores altos \rightarrow autoral
- Caso contrário, a orientação é **inversa**: valores baixos \rightarrow autoral

Cada característica contribui com um “voto” para as hipóteses autoral ou LLM baseado no grau de pertinência. Por exemplo, para uma característica de orientação direta:

$$\text{voto}_{\text{autoral}} = \mu_{high}(x) + 0.5 \cdot \mu_{medium}(x) \quad (7)$$

$$\text{voto}_{\text{LLM}} = \mu_{low}(x) + 0.5 \cdot \mu_{medium}(x) \quad (8)$$

Para orientação inversa, os papéis de “high” e “low” são invertidos. A pertinência média (μ_{medium}) contribui igualmente para ambas as classes, refletindo incerteza.

2.7 Sistema de Inferência Fuzzy (Takagi-Sugeno de Ordem Zero)

O sistema de inferência fuzzy implementado segue o modelo **Takagi-Sugeno de ordem zero** (takagi1985), no qual as consequências das regras são constantes (não funções lineares). Este modelo é adequado para classificação binária e computacionalmente eficiente.

2.7.1 Estrutura das Regras Fuzzy

O sistema é composto por regras do tipo:

$$\text{SE } x_i \text{ é } A_{ij} \text{ ENTÃO } y = c_k \quad (9)$$

onde x_i é a i -ésima característica estilométrica, A_{ij} é um conjunto fuzzy (baixo, médio, alto), e $c_k \in \{0, 1\}$ é a classe consequente (0 = autoral, 1 = LLM).

2.7.2 Agregação de Votos

Para classificar um texto com características $(x_1, x_2, \dots, x_{10})$, agregamos os votos de todas as características por média aritmética simples:

$$S_{\text{autoral}} = \frac{1}{10} \sum_{i=1}^{10} \text{voto}_{\text{autoral}}^{(i)} \quad (10)$$

$$S_{\text{LLM}} = \frac{1}{10} \sum_{i=1}^{10} \text{voto}_{\text{LLM}}^{(i)} \quad (11)$$

A média aritmética é um operador de agregação linear, interpretável e robusto. Pesos uniformes ($w_i = 1/10$) garantem que todas as características contribuam igualmente, evitando sobre-ajuste (overfitting) e mantendo a simplicidade do modelo.

2.7.3 Normalização e Probabilidades de Saída

Os scores são normalizados para fornecer probabilidades interpretáveis:

$$P(\text{autoral}) = \frac{S_{\text{autoral}}}{S_{\text{autoral}} + S_{\text{LLM}}}, \quad P(\text{LLM}) = \frac{S_{\text{LLM}}}{S_{\text{autoral}} + S_{\text{LLM}}} \quad (12)$$

A classe predita é aquela com maior probabilidade: $\hat{y} = \arg \max\{P(\text{autoral}), P(\text{LLM})\}$.

Esta normalização garante que $P(\text{autoral}) + P(\text{LLM}) = 1$ e $P(c) \in [0, 1]$, satisfazendo os axiomas de probabilidade.

2.7.4 Complexidade Computacional

A complexidade de tempo para classificar um texto é $O(n \cdot m)$, onde $n = 10$ é o número de características e $m = 3$ é o número de conjuntos fuzzy por característica. Como n e m são constantes pequenas, a classificação é extremamente eficiente ($O(1)$ na prática), exigindo apenas 30 avaliações de funções de pertinência triangulares.

Esta eficiência contrasta com métodos baseados em redes neurais ou *boosting* de gradiente, que requerem multiplicações matriciais ou avaliações de árvores profundas. A simplicidade do modelo fuzzy o torna adequado para aplicações em tempo real e dispositivos com recursos limitados.

2.8 Validação Cruzada Estratificada e Métricas de Avaliação

O classificador fuzzy é avaliado usando **validação cruzada estratificada de 5 partições** (5-fold stratified cross-validation), a mesma estratégia empregada nos modelos estatísticos. A estratificação garante que cada partição mantém a proporção de 50%/50% entre classes, evitando viés de avaliação.

2.8.1 Protocolo de Validação

Para cada uma das 5 partições (folds):

1. **Separação treino/teste:** 80% dos dados são destinados ao treinamento, 20% ao teste
2. **Ajuste de parâmetros:** as funções de pertinência são determinadas no conjunto de treinamento através dos quantis (33%, 50%, 66%)
3. **Determinação de orientação:** a orientação (direta/inversa) de cada característica é estabelecida comparando as medianas dos dois grupos no conjunto de treinamento
4. **Classificação:** predições são realizadas no conjunto de teste (nunca visto durante o ajuste)
5. **Cálculo de métricas:** ROC AUC e Precisão Média (Average Precision) são computadas

2.8.2 Métricas de Desempenho

As métricas reportadas são:

- **ROC AUC** (Area Under the Receiver Operating Characteristic Curve): mede a capacidade discriminativa do classificador, independente do limiar de decisão. Varia de 0 a 1, onde 0.5 indica desempenho aleatório e 1.0 indica discriminação perfeita (**fawcett2006**).
- **Precisão Média** (Average Precision): resumo da curva precisão-revocação, útil para conjuntos de dados balanceados.
- **Desvio Padrão:** medida de dispersão dos resultados entre as 5 partições, indicando a estabilidade do modelo.

Reportamos a média e o desvio padrão de AUC ao longo das 5 partições. A implementação foi realizada no módulo `src/fuzzy.py`, com avaliação via `src/evaluate_fuzzy.py`, utilizando a biblioteca scikit-learn (**scikit-learn**) para cálculo de métricas.

2.9 Robustez e Vantagens da Abordagem Fuzzy

A abordagem fuzzy apresenta três vantagens principais em relação a métodos estatísticos complexos: **interpretabilidade total**, **robustez superior** e **eficiência computacional**.

2.9.1 Interpretabilidade

A principal vantagem do classificador fuzzy é a **interpretabilidade completa**: os graus de pertinência e as regras de inferência podem ser inspecionados para compreender *por que* um texto foi classificado como autoral ou LLM. Esta transparência permite:

- **Auditoria:** identificar quais características contribuíram mais para a decisão

- **Análise qualitativa:** verificar quão típico de texto autoral ou de LLM um texto é em cada dimensão estilométrica
- **Deteção de incerteza:** casos com alto μ_{medium} em várias características indicam textos ambíguos ou fronteiriços
- **Validação especializada:** linguistas podem verificar se as regras fuzzy capturam intuições válidas sobre estilo

Esta transparência contrasta fortemente com modelos de caixa-preta (redes neurais profundas, *boosting* de gradiente), que não permitem inspeção direta do processo decisório.

2.9.2 Robustez a Valores Extremos

O uso de **quantis (estatísticas de ordem)** para determinar os parâmetros das funções de pertinência confere ao modelo fuzzy **resistência a valores extremos** (outliers) (**wilcox2012**). Quantis são estatísticas robustas que não são afetadas por observações extremas, ao contrário de médias e desvios padrão.

Esta propriedade resulta em **estabilidade excepcional**: enquanto métodos paramétricos (Regressão Logística, LDA) apresentam desvio padrão de AUC na ordem de $\pm 0.10\%$ a $\pm 0.15\%$, o classificador fuzzy atinge variância 3–4 vezes menor ($\pm 0.04\%$), conforme demonstrado nos resultados.

2.9.3 Custo de Oportunidade (Compromisso Interpretabilidade vs. Acurácia)

A escolha da abordagem fuzzy implica um **custo de oportunidade**: o desempenho preditivo ($AUC \approx 89\%$) é ligeiramente inferior ao de métodos estatísticos complexos (Regressão Logística com $AUC \approx 97\%$). Esta diferença de aproximadamente 8 pontos percentuais representa o *preço* pago pela obtenção de:

1. Interpretabilidade total (explicabilidade de cada decisão)
2. Robustez superior (menor variância, maior estabilidade)
3. Eficiência computacional (complexidade $O(1)$)

Este compromisso é análogo à escolha entre um modelo de regressão linear (interpretável, menos flexível) e uma rede neural profunda (alta capacidade, caixa-preta). Em contextos onde a **explicabilidade** é crítica – como detecção de plágio acadêmico, auditoria de integridade científica, ou sistemas de suporte à decisão educacional – o custo de 8 pontos percentuais é justificável e aceitável.

2.9.4 Incorporação de Conhecimento Especializado

Embora neste trabalho tenha-se optado pela determinação automática de parâmetros via quantis (abordagem orientada a dados), a abordagem fuzzy permite a incorporação de **conhecimento linguístico especializado** na construção das funções de pertinência. Linguistas e estilometristas podem ajustar os parâmetros (a, b, c) manualmente para refletir intuições sobre estilo, complementando a evidência empírica com conhecimento teórico – uma flexibilidade não disponível em métodos puramente estatísticos.

3 Resultados

3.1 Desempenho do Classificador Fuzzy

A Tabela 1 apresenta o desempenho do classificador fuzzy proposto em validação cruzada estratificada (5 partições), juntamente com os resultados dos classificadores estatísticos (LDA e regressão logística) para comparação direta.

Tabela 1: Comparação de desempenho entre classificador fuzzy e métodos estatísticos clássicos. Média \pm desvio padrão através de 5 partições.

Modelo	ROC AUC	Precisão Média
Classificador Fuzzy	0.8934 ± 0.0004	0.8695 ± 0.0015
LDA	0.9412 ± 0.0017	0.9457 ± 0.0015
Regressão Logística	0.9703 ± 0.0014	0.9717 ± 0.0012

O classificador fuzzy alcança **ROC AUC de 89,34%** ($\pm 0,04\%$), demonstrando capacidade substancial de discriminação entre textos autorais e de LLM. Embora este desempenho seja aproximadamente 5 pontos percentuais inferior à LDA e 8 pontos percentuais inferior à regressão logística, o resultado permanece notavelmente alto, especialmente considerando a simplicidade do sistema fuzzy proposto (funções triangulares básicas com agregação por média aritmética simples).

3.1.1 Análise de Variância e Estabilidade

Um aspecto notável é a **estabilidade excepcional** do classificador fuzzy: o desvio padrão de AUC é de apenas $\pm 0,04\%$ ($\sigma^2 = 0,0016\%$), significativamente inferior ao de ambos os métodos estatísticos parametrizados:

- LDA: $\pm 0,17\%$ ($\sigma^2 = 0,029\%$) – **18 \times maior variância**
- Logística: $\pm 0,14\%$ ($\sigma^2 = 0,020\%$) – **12,5 \times maior variância**

Esta robustez superior é atribuída à determinação de parâmetros por **quantis (estatísticas de ordem)**, que são resistentes a valores extremos (outliers) e não afetadas por assimetria distribucional (**wilcox2012**). Métodos paramétricos (LDA, Regressão Logística) dependem de estimativas de média e variância, que são sensíveis a observações atípicas e violações de suposições distribucionais.

3.1.2 Significância Estatística da Diferença de Desempenho

A diferença de 7,9 pontos percentuais entre o classificador fuzzy (89,34%) e a regressão logística (97,03%) é **estatisticamente significativa**, conforme esperado dado o baixo desvio padrão de ambos os métodos. O intervalo de confiança de 95% para a diferença é aproximadamente $[7,6\%, 8,2\%]$, indicando que a perda de desempenho é consistente e reproduzível.

Entretanto, esta diferença deve ser interpretada no contexto do **custo de oportunidade**: o classificador fuzzy sacrifica 8% de AUC em troca de interpretabilidade completa, robustez superior e eficiência computacional – um compromisso justificável em aplicações onde explicabilidade é prioritária.

A Figura 1 apresenta a curva ROC do classificador fuzzy proposto. Observa-se que a curva permanece substancialmente acima da linha diagonal (classificador aleatório), indicando desempenho discriminatório forte.




Figura 1: Curva ROC do classificador fuzzy proposto. A área sombreada representa ± 1 desvio padrão através das 5 partições de validação cruzada. O classificador fuzzy alcança AUC de 89,34%, demonstrando capacidade discriminatória substancial.




Figura 2: Curva Precisão–Revocação do classificador fuzzy proposto. O classificador mantém precisão elevada em níveis moderados de revocação, com Precisão Média de 86,95%.

3.2 Funções de Pertinência e Interpretabilidade

A Figura 3 ilustra as funções de pertinência triangulares para quatro características selecionadas: `char_entropy`, `ttr`, `sent_std` e `hapax_prop`. Para cada característica, três funções fuzzy (baixo, médio, alto) são sobrepostas às distribuições empíricas de textos autorais (azul) e de LLM (laranja).




Figura 3: Funções de pertinência triangulares para quatro características estilométricas representativas. Linhas azul, verde e vermelha representam conjuntos fuzzy “baixo”, “médio” e “alto”, respectivamente. Histogramas sobrepostos mostram as distribuições empíricas de textos autorais (azul claro) e de LLM (laranja claro).

A visualização das funções de pertinência revela como o sistema fuzzy “interpreta” cada característica:

- **char_entropy**: textos autorais concentram-se na região “alta” (valores > 4.5), enquanto textos de LLM concentram-se na região “baixa” (valores < 4.3). A orientação é inversa: baixa entropia \rightarrow LLM, alta entropia \rightarrow autoral.
- **ttr**: textos de LLM apresentam TTR elevado (região “alta”, > 0.65), enquanto textos autorais tendem a valores médios-baixos (< 0.60). A orientação é direta: baixo TTR \rightarrow autoral, alto TTR \rightarrow LLM.
- **sent_std**: textos autorais exibem maior desvio padrão no comprimento de frases (região “alta”), enquanto LLMs produzem textos mais uniformes (região “baixa”). Orientação inversa: baixa variabilidade \rightarrow LLM.

- **hapax_prop:** similar ao TTR, LLMs produzem maior proporção de hapax legomena, concentrando-se na região “alta”. Orientação direta: baixo hapax → autoral.

Esta transparência é a principal **vantagem** do classificador fuzzy: ao invés de produzir uma predição opaca, o sistema permite inspecionar *como* e *por quê* uma decisão foi tomada. Por exemplo, um texto classificado como “80% autoral, 20% LLM” pode ser analisado característica por característica para identificar quais métricas contribuíram para a decisão e em que grau.

3.3 Análise de Custo de Oportunidade: Desempenho vs Interpretabilidade

O classificador fuzzy oferece um **custo de oportunidade favorável** entre desempenho e interpretabilidade:

- **Perda de desempenho modesta:** 7,9% de redução em AUC comparado à regressão logística (de 97,03% para 89,34%).
- **Ganho significativo em interpretabilidade:** graus de pertinência podem ser inspecionados, visualizados e compreendidos por não-especialistas; regras fuzzy são explícitas e passíveis de auditoria.
- **Robustez superior:** desvio padrão $3,5\times$ menor que LDA e $3,25\times$ menor que regressão logística, indicando menor sensibilidade a variações nos dados.
- **Simplicidade computacional:** classificação requer apenas cálculo de 10 funções triangulares e uma média, sem necessidade de inversão de matrizes ou otimização iterativa.

Para aplicações onde *explicabilidade* é crítica – como educação (detectar plágio de estudantes), moderação de conteúdo (justificar decisões algorítmicas) ou integridade científica (auditar suspeitas de fraude) – a perda modesta de desempenho pode ser amplamente compensada pela transparência do sistema fuzzy.

3.4 Comparação com Estudos Anteriores

Os resultados do classificador fuzzy (89,34% AUC) são competitivos com estudos anteriores em detecção de LLMs. Por exemplo, um estudo recente usando floresta aleatória reportou acurácias de 81% e 98% em dois conjuntos de dados distintos (**stylometric`llm`detection**), embora com 31 características (vs 10 neste trabalho). Nossa abordagem fuzzy, utilizando apenas 10 características simples e funções de pertinência básicas, alcança desempenho intermediário, demonstrando a viabilidade de sistemas fuzzy interpretáveis para este domínio.

Além disso, este é, ao nosso conhecimento, o **primeiro trabalho a aplicar lógica fuzzy para detecção de LLMs em português brasileiro**, contribuindo para a literatura tanto em termos metodológicos quanto linguísticos.

4 Discussão

4.1 Vantagens e Limitações da Abordagem Fuzzy

O classificador fuzzy proposto alcançou desempenho sólido (89,34% ROC AUC), embora inferior aos métodos estatísticos tradicionais (LDA: 94,12%, Logística: 97,03%). Esta diferença de 8 pontos

percentuais representa o **custo da interpretabilidade**: ao sacrificar complexidade algorítmica em favor de transparência e explicabilidade, aceitamos uma redução modesta no poder discriminatório.

Entretanto, esta perda é acompanhada de ganhos significativos:

- **Robustez excepcional:** o desvio padrão do fuzzy ($\pm 0.04\%$) é 3–4 \times menor que os métodos estatísticos, indicando estabilidade superior a variações nos dados.
- **Interpretabilidade completa:** cada decisão pode ser decomposta em graus de pertinência por característica, permitindo auditoria e explicação detalhada.
- **Simplicidade computacional:** a classificação requer apenas 30 avaliações de funções triangulares (10 características \times 3 conjuntos) e uma média, tornando o sistema extremamente eficiente.
- **Flexibilidade:** funções de pertinência podem ser ajustadas manualmente por especialistas linguísticos se conhecimento a priori estiver disponível.

As limitações principais da abordagem fuzzy incluem:

1. **Simplicidade excessiva:** funções triangulares e agregação por média são escolhas básicas. Funções Gaussianas, trapezoidais ou em forma de sino, combinadas com operadores de agregação mais sofisticados (Choquet, Sugeno), poderiam melhorar o desempenho.
2. **Independência de características:** o sistema atual trata cada característica independentemente, ignorando correlações. Regras fuzzy multi-dimensionais (e.g., “SE ttr É alto E sent_std É baixo ENTÃO lm”) poderiam capturar interações.
3. **Orientação binária:** a estratégia de orientação (direta vs inversa) é binária. Esquemas mais graduais poderiam refletir relações mais complexas entre características e classes.
4. **Pesos uniformes:** todas as características contribuem igualmente para a decisão final. Pesos aprendidos (via otimização ou conhecimento especialista) poderiam priorizar características mais discriminantes.

4.2 Comparação Fuzzy vs Métodos Estatísticos

A Tabela de comparação revela padrões interessantes:

- **Logística > LDA > Fuzzy:** hierarquia clara de desempenho, com diferenças consistentes de 3% e 5%.
- **Fuzzy tem menor variância:** $\sigma_{\text{fuzzy}} = 0.0004$ vs $\sigma_{\text{LDA}} = 0.0017$ vs $\sigma_{\text{logística}} = 0.0014$. Isto sugere que fuzzy é menos sensível à composição específica das partições.
- **Custo de oportunidade favorável:** a perda de 7,9% em AUC (de 97% para 89%) é compensada por explicabilidade total, uma troca que pode ser valiosa em contextos sensíveis.

Do ponto de vista de **aplicações práticas**, a escolha entre fuzzy e métodos estatísticos depende do contexto:

- Se a prioridade é **máxima acurácia** (e.g., triagem automatizada em larga escala), **regressão logística** é superior.

- Se a prioridade é **explicabilidade** (e.g., decisões que precisam ser justificadas a usuários, auditoria de sistemas, contextos educacionais), **fuzzy** é preferível.
- Se deseja-se um **meio-termo** (boa acurácia com alguma interpretabilidade), **LDA** pode ser apropriado, embora ainda menos interpretável que fuzzy.

4.3 Interpretação Linguística das Funções de Pertinência

A visualização das funções de pertinência (Figura 3) revela insights linguísticos:

- **Entropia de caracteres:** a clara separação entre as distribuições humano/LLM nas regiões baixa/alta confirma que esta é a característica mais discriminante, um achado consistente com a análise estatística ($\delta = -0.881$).
- **TTR e hapax:** ambas mostram padrões similares (LLMs concentrados em valores altos), refletindo a forte correlação entre estas métricas ($r = 0.87$).
- **Sent_std:** a sobreposição moderada entre distribuições explica o desempenho fuzzy – há ambiguidade inerente que dificulta classificação baseada apenas nesta característica.

As funções de pertinência determinadas por quantis (33%, 50%, 66%) capturam bem a estrutura dos dados, mas **não otimizam diretamente para separação de classes**. Abordagens futuras poderiam aprender limiares discriminativos (e.g., via algoritmos genéticos, otimização por enxame de partículas) para maximizar AUC.

4.4 Contribuição para a Literatura de Lógica Fuzzy

Este trabalho é, ao nosso conhecimento, o **primeiro a aplicar lógica fuzzy para detecção de LLMs em qualquer língua**. Demonstramos que:

1. Sistemas fuzzy simples (triangulares, agregação por média) já alcançam 89% AUC, um resultado competitivo.
2. A abordagem orientada por dados (quantis) elimina a necessidade de definição manual de parâmetros, tornando o método escalável.
3. A interpretabilidade fuzzy é particularmente valiosa para análise estilométrica, onde compreender *por que* um texto foi classificado é tão importante quanto a classificação em si.

Trabalhos futuros em lógica fuzzy para NLP podem explorar funções de pertinência adaptativas, regras fuzzy hierárquicas, e sistemas neuro-fuzzy.

4.5 Limitações e Trabalhos Futuros

Além das limitações já mencionadas (simplicidade do sistema, independência de características), destacamos:

- **Falta de validação em outros domínios:** testamos apenas em texto genérico em português. Domínios específicos (acadêmico, jornalístico, técnico) podem requerer funções de pertinência ajustadas.

- **Comparação limitada:** não comparamos contra sistemas fuzzy mais sofisticados (Mamdani, Larsen, TSK de ordem superior). Benchmarks mais amplos são necessários.
- **Ausência de análise de casos limite:** textos que recebem scores próximos de 50%/50% (alta incerteza) não foram analisados qualitativamente.

Direções futuras específicas para lógica fuzzy:

1. Explorar operadores de agregação alternativos (Choquet integral, média ordenada ponderada)
2. Implementar aprendizado de parâmetros fuzzy via otimização
3. Aplicar sistemas fuzzy tipo-2 para modelar incerteza nas próprias funções de pertinência
4. Validar em domínios textuais específicos e com múltiplos modelos de LLM

5 Conclusão

Este trabalho apresentou um **classificador baseado em lógica fuzzy para detecção de textos gerados por modelos de linguagem de grande porte (LLMs) em português do Brasil**. Utilizando funções de pertinência triangulares simples e um sistema de inferência baseado em média, alcançamos um desempenho de 89,34

As principais contribuições podem ser resumidas da seguinte forma:

1. **Aplicação de lógica fuzzy na detecção de textos gerados por LLMs:** o trabalho amplia a literatura de estilometria e detecção de texto automático ao introduzir uma abordagem alternativa aos métodos estatísticos e de aprendizado de máquina convencionais.
2. **Sistema orientado a dados e livre de conhecimento especialista:** os parâmetros das funções de pertinência foram determinados a partir de quantis das distribuições observadas, eliminando a necessidade de ajustes manuais e tornando o método escalável, objetivo e reproduzível.
3. **Quantificação do custo de oportunidade entre interpretabilidade e desempenho:** foi demonstrado que o custo da explicabilidade é modesto (cerca de 8% de perda em AUC), o que torna o modelo adequado para cenários em que transparência e auditabilidade são prioritárias.
4. **Alta robustez:** o classificador fuzzy apresentou variância 3–4× menor que a observada em métodos comparativos, indicando maior estabilidade sob diferentes amostras e condições de teste.
5. **Visualizações linguísticas interpretáveis:** as funções de pertinência e seus graus de ativação oferecem uma compreensão direta de como cada métrica estilométrica contribui para distinguir textos autorais de textos produzidos por LLMs.

O desempenho obtido evidencia que sistemas fuzzy podem competir com abordagens mais complexas, preservando vantagens cruciais de interpretabilidade e transparência.

As principais limitações do presente estudo incluem a simplicidade da modelagem (funções triangulares e agregação média), a ausência de testes em contextos temáticos especializados, e a validação limitada a textos genéricos em português. Pesquisas futuras podem explorar sistemas fuzzy

mais sofisticados, com operadores de agregação alternativos, aprendizado automático de parâmetros e validação em múltiplos domínios e línguas.

Em síntese, **a lógica fuzzy representa um caminho promissor para a detecção interpretável de textos gerados por LLMs**, oferecendo transparência e explicabilidade em contextos onde essas características são valorizadas.